



Berner Fachhochschule
Haute école spécialisée bernoise
Bern University of Applied Sciences

CAS Datenanalyse

Kapitel 3: Modellauswahl und F-Test

Prof. Dr. Raúl Gimeno
FRM, CAIA, PRM

1

Inhalt

Informationskriterien:

- ✓ Akaike
- ✓ Schwarz
- ✓ Hannan-Quinn

T-Test: Beschränkung

t-Test für Linearkombination von Parametern

F-Verteilung

F-Test

F-Test für Restriktionen

Gutes Regressionsmodell

- **Relevanz**: Das Modell sollte der Fragestellung entsprechen
- **Theoretische Konsistenz**: Logisch widerspruchsfrei, geschätzte Parameter → erwartete Vorzeichen
- **Einfachheit** (Parsimony): So einfach wie möglich
- **Anpassung** (goodness of fit): Verfügbaren Daten möglichst gut abbilden
- **Prognosefähigkeit**: Gute Prognosen liefern

Trade-off: **Anpassungsgüte** und **Komplexität**, gemessen an der Anzahl der Parameter, ausbalancieren.

Top-down Vorgehen: Möglichst umfassendes Modell → durch Tests ein adäquates Modell wählen

Problem: Keine Zauberformel liefert automatisch das «bestes Modell».

Ziel: Kriterium zur **Auswahl** eines geeigneten Regressionsmodells unter konkurrierenden Modellen.

Informationskriterium: Fitmass

Kriterium: Die Anzahl der Parameter wird dabei "strafend" berücksichtigt, da sonst **komplexe Modelle** mit vielen Parametern bevorzugt würden.

Alternative zu \bar{R}^2 : Abwägung des **Verzerrungsrisikos** und des Risikos einer zu grossen Schätzvarianz.

Selektionskriterium = **Fitmass** + Anzahl Parameter × Straffunktion

Fitmass

Misst, wie gut sich das geschätzte Modell an die Daten anpasst.

Problem: Zusätzliche Parameter führen im Allgemeinen zu einer **Fitverbesserung**, niemals jedoch zu einer Fitverschlechterung.

Auswahl: Minus zweimal die **Log-Likelihood Funktion**

Unterscheidet sich für eine gegebene **Stichprobengrösse N** nur um eine Konstante von s^2 .

OLS-Likelihoodfunktion: $\ell(\mathbf{b}) = -(N/2)[1 + \ln 2\pi + \ln(RSS/N)]$

$$RSS = \sum_i (y_i - \hat{y}_i)^2 = S_{ee}$$

Informationskriterium: Strafterm

Strafterm:

Produkt aus Zahl der geschätzten Parameter k und **Strafffunktion**:

- Der Strafterm bestraft die Anzahl der Parameter, um zu vermeiden, dass **überflüssige Variablen** mit ins Modell aufgenommen werden und somit das Schätzverfahren **ineffizient** wird.
- Der Strafterm steigt mit steigendem K (# Regressoren)
- **Trade-off**: Regressoren werden dann in das Modell aufgenommen, wenn die Strafe geringer ausfällt als die Verbesserung des Fit.
- Durch die Wahl der Straffunktion (und damit des Kriteriums) legt man fest, wie dieser Trade-off **quantitativ** vorgenommen wird. Gängig sind drei verschiedene Kriterien: AIC, SIC und HQ.

Informationskriterium: Akaike

gretl: $AIC = l(b) + 2k$ $AIC = N \ln \left(\frac{RSS}{N} \right) + 2K + N \left((1 + \ln(2\pi)) \right)$

Andere Software: $AIC^* = \ln \left(\frac{RSS}{N} \right) + 2K$

$AIC^* = AIC/N - (1 + \ln(2\pi))$

Hinweis: Je nach Software-Paket unterschiedliche Implementierung der verschiedenen Informationskriterien.

	Modell 1	Modell 2	Modell 3
N	20	20	20
K	2	3	4
Variablen	1	1, 2	1, 2 und 3
$S_{ee} = e'e$	1'260'028	957'698.10	955'691.70
gretl AIC	281.7758	278.2887	280.2467
AIC*	11.251	11.077	11.174

Y: Lohnhöhe
1: Ausbildung
2: Alter
3: Firmenzugehörigkeit

residuale Variation

Regel: Unter allen konkurrierenden Regressionsmodellen wird die **Spezifikation** gewählt, für die das Informationskriterium den **kleinsten Wert** annimmt.

Informationskriterium: SIC und HQC

Schwarz Informationskriterium / Bayessches Informationskriterium (BIC)

$$\text{SIC} = -2l(\mathbf{b}) + K \ln(N)$$

$$\text{Strafterm: } K \ln(N)$$

Faktor des Strafterms wächst logarithmisch mit der Anzahl der Beobachtungen N .

Bereits ab acht Beobachtungen ($\ln 8 = 2.07944 > 2$) bestraft das SIC zusätzliche Parameter schärfer als das AIC.

Hannan-Quinn Kriterium (HQC)

$$\text{HQC} = -2l(\mathbf{b}) + 2K \ln[\ln(N)]$$

$$\text{Strafterm: } 2K \ln[\ln(N)]$$

In günstigen Fällen führen alle Kriterien zur gleichen Modellauswahl.

SIC bestraft für Stichprobengrößen ($n > 8$) zusätzliche Parameter stärker als HQ, und HQ wiederum stärker als AIC.

Informationskriterien: Beispiel

Regel: Unter allen konkurrierenden Regressionsmodellen wird die Spezifikation gewählt, für die das Informationskriterium den kleinsten Wert annimmt.

Korrektes Modell 2: $y = b_1 + b_2 \text{Ausbildung} + b_3 \text{Alter} + b_4 \text{Dauer}$

	Modell 1	Modell 2	Modell 3	
N	20	20	20	
K	2	3	4	
Variablen	1	1, 2	1, 2 und 3	Strafterm
AIC	281.775	278.288	280.246	2K
SIC	283.767	281.275	284.229	$K \ln(N)$
HQC	282.164	278.871	281.024	$2K \ln(\ln(N))$

Ungünstiger Fall: Die verschiedenen Kriterien führen zu widersprüchlichen Ergebnissen.

Variablenauswahl: t- und F-Tests

gretl Output-Fenster

Modell 3: KQ, benutze die Beobachtungen 1-20

Abhängige Variable: Lohn

	Koeffizient	Std.-fehler	t-Quotient	p-Wert
const	1000,45	225,727	4,432	0,0004 ***
Ausbildung	62,4284	21,8345	2,859	0,0114 **
Alter	12,3539	10,6575	1,159	0,2634
Dauer	-2,62034	14,2970	-0,1833	0,8569

Mittel d. abh. Var.	1685,000	Stdabw. d. abh. Var.	375,6048
Summe d. quad. Res.	955691,7	Stdfehler d. Regress.	244,3987
R-Quadrat	0,643465	Korrigiertes R-Quadrat	0,576615
F(3, 16)	9,625466	P-Wert (F)	0,000720

1 Log-Likelihood	-136,1234	2 Akaike-Kriterium	280,2467
3 Schwarz-Kriterium	284,2296	4 Hannan-Quinn-Kriterium	281,0242

1. $l(b) = -\frac{N}{2}(1 + \ln 2\pi - \ln N) - \frac{N}{2} \ln \text{RSS} = -136.1234$
2. $\text{AIC} = -2l(b) + 2k = -2(-136.1234) + 2 \times 3 = 280.2467$
3. $\text{SIC} = -2l(b) + k \ln N = -2(-136.1234) + 3 \ln(20) = 284.2296$
4. $\text{HQC} = -2l(b) + 2k \ln[\ln N] = -2(-136.1234) + 6 \ln[\ln(20)] = 281.0242$

Modellauswahl mittels AIC

Megamodell mit 4 Variablen: $X_1, X_2, X_3, X_4 \rightarrow \text{AIC} = 159.55$
 # Modelle: $2^4 = 16$

	AIC		AIC	
Interzept	208.75	X_2, X_3	166.97	
X_1	169.3	X_2, X_4	166.97	
X_2	190.79	X_3, X_4	164.16	
X_3	170.20	X_1, X_2, X_3	168.40	
X_4	166.02	X_1, X_2, X_4	158.01	
X_1, X_2	169.61	X_1, X_3, X_4	157.55	
X_1, X_3	167.14	X_2, X_3, X_4	165.78	
X_1, X_4	156.01			

Hypothesentests mittels t-Test

Mit dem t-Test kann überprüft werden, ob ein geschätzter Koeffizient einem theoretisch angenommenen Wert (b_i) entspricht.

Prüfgrösse: **t-Wert**

$$t_i = \frac{b_i - \beta_i}{se(b_i)} \sim t_{N-k}$$

$$t(S) = \frac{b_i - c}{se(b_i)} \sim t_{N-k} \quad \text{wenn } H_0: \beta_i = c \quad \text{wahr}$$

S: Menge aller möglichen Stichproben

Teststatistik $t(S)$: Funktion der **Stichproben S**.

Gilt nur wenn $H_0: \beta_i = c$ **wahr**

Formulierung einer **Alternativhypothese**.

$$H_{1a}: b_i \neq c$$

$$H_{1b}: b_i > c$$

$$H_{1c}: b_i < c$$

t-Test: Stichprobenkennwertverteilung

$$t_i = \frac{b_i - \beta_i}{se(b_i)} \sim t_{N-k} \quad \text{wenn } H_0: \beta_i = c \quad \text{wahr}$$


Der Wert der **Teststatistik t** wird desto näher bei null liegen, je geringer die Distanz zwischen dem **Schätzer b_i** und dem unter H_0 vermuteten Wert **c** ist!

Für jede Stichprobe den Wert der **Teststatistik t** berechnen

Bei **unendlich vielen Stichproben** mit Umfang **N** (hypothetisch) →

Histogramm all dieser t-Werte → t-Werte sind **t-verteilt**.

Stichprobenkennwertverteilung von $t(S)$ unter H_0



Bewertung der Parameter

Regressionsfunktion ($K = 3$): $y_t = \beta_1 + \beta_2 x_{2t} + \beta_3 x_{3t} + u_t$

Frage: Trägt der Regressor x_i zur Erklärung von y bei?

Test von $H_0: \beta_i = 0$ gegen $H_1: \beta_i > 0$ oder $H_1: \beta_i \neq 0$ (zweiseitig)

Interpretation: Erklärende Variable x_i hat **keinen partiellen Effekt** auf y

t-Verteilung für standardisierten Schätzer: $\frac{b_i - \beta_i}{se(b_i)} \sim t_{N-k}$

N: Stichprobengrösse

K: Anzahl Parameter

t-verteilte Statistik: $t_i = \frac{b_i}{se(b_i)} \sim t_{N-3}$ when $H_0: \beta_i = 0$ wahr

Interpretation t_i : Wie viele **Standardabweichungen** liegt b_i von null entfernt?

Nullhypothese

Ein **statistisches Testproblem** (statistischer Test) besteht aus einer **Nullhypothese** H_0 und einer **Alternativhypothese** H_1 , die sich gegenseitig ausschliessen.

Regeln für das Aufstellen der Nullhypothese:

- ✓ Was ich zeigen oder beweisen will, gehört in die Alternativhypothese
- ✓ Das Gleichheitszeichen gehört immer in die **Nullhypothese**

Die **Annahme** der Nullhypothese führt immer zur Ablehnung der **Alternativhypothese** ist aber **kein Beweis** dafür, dass die Nullhypothese stimmt.

Die **Ablehnung** der Nullhypothese führt zur Annahme der **Alternativhypothese**.

Gretl-Output: Signifikanzniveau

Modell 3: KQ, benutze die Beobachtungen 1-20
Abhängige Variable: Lohn

	Koeffizient	Std.-fehler	t-Quotient	p-Wert
const	1000,45	225,727	4,432	0,0004 ***
Ausbildung	62,4284	21,8345	2,859	0,0114 **
Alter	12,3539	10,6575	1,159	0,2634
Dauer	-2,62034	14,2970	-0,1833	0,8569
Mittel d. abh. Var.	1685,000	Stdabw. d. abh. Var.	375,6048	
Summe d. quad. Res.	955691,7	Stdfehler d. Regress.	244,3987	
R-Quadrat	0,643465	Korrigiertes R-Quadrat	0,576615	
F(3, 16)	9,625466	P-Wert (F)	0,000720	

1%-Niveau

5%-Niveau

$$t_i = \frac{b_i}{se(b_i)}$$

Faustregel: $|t| > 2 \rightarrow H_0: b_i = 0$ verwerfen

Mittels hochgestellten Sternen * neben dem p-Wert wird kenntlich gemacht, auf welchem **Signifikanzniveau** α die Nullhypothese $b_i = 0$ verworfen werden kann.

* - Signifikant auf dem **10%** Niveau

** - Signifikant auf dem **5%** Niveau

*** - Signifikant auf dem **1%** Niveau \rightarrow Koeffizient hoch signifikant

Beschränkung des t-Tests

Statistische Signifikanz vs. theoretische Validität

Einfaches Regressionsmodell mit $y = \text{UK Konsumentenpreisindex}$

Schätzfunktion: $\hat{y} = 10.9 - 3.2x + 0.39x^2$ $N = 21, \bar{R}^2 = 0.982$

(0.23) (0.02)

$t = -13.9 \quad 19.5$

$H_0: b_2 = 0$ und $H_0: b_3 = 0$ zweiseitiger Test $\rightarrow H_0$ ablehnen

Konklusion: x und x^2 statistisch signifikante Variablen für die Erklärung von y .

x : kumulierte Niederschlagsmenge in UK !

Grund der **Signifikanz**: Beide Variablen weisen einen Trend auf

Ungültiges Modell! \rightarrow Regression ohne theoretische Fundierung \rightarrow

Gefahr: Es wird nur noch geprüft, ob die Daten etwas aussagen können!

Beschränkung des t-Tests

t-Test und Wichtigkeit einer Variable

- Statistische Signifikanz gibt Aufschluss darüber, dass ein bestimmtes Stichprobenschätzergebnis **nicht** reiner Zufall ist.
- Keine Aussage darüber, welche Variable den grössten Teil der Variation von y erklärt
- **Schlussfolgerung**: Variable mit dem signifikantesten Koeffizienten (höchster t-Wert) ist nicht unbedingt die wichtigste Variable (grösster Effekt auf Y)

t-Test bei hohen Stichprobenumfängen

- Stichprobenumfang $N \uparrow$: Unverzerrter Schätzwert eines Parameters liegt immer näher am wahren Parameter der Grundgesamtheit.
- $se(b_i) \downarrow \rightarrow t_i \uparrow \rightarrow H_0$ verwerfen

$$t_i = \frac{b_i - \beta_i}{se(b_i)} \sim t_{N-k}$$

- Bedeutung einer Variablen für y nicht alleine mit der Signifikanz beurteilen

t-Test für eine Linearkombination von Parametern

Regressionsfunktion: $y_t = \beta_1 + \beta_2 x_{2t} + \beta_3 x_{3t} + u_t$

$H_0: c_1 \beta_2 + c_2 \beta_3 = c$ $H_1: c_1 \beta_2 + c_2 \beta_3 \neq c$

Beispiel 1: Parameter β_2 und β_3 weisen den gleichen Wert auf

Formulierung $H_0: \beta_2 - \beta_3 = 0$ ($c_1 = c_2 = 1$)

Beispiel 2: Parameter β_3 ist halb so gross wie β_2 aber mit unterschiedlichem Vorzeichen.

Formulierung $H_0: \beta_2 + 2\beta_3 = 0$ ($c_1 = 1$ und $c_2 = 2$)

Allgemeines Test-Prinzip: Wenn $H_0: c_1 \beta_2 + c_2 \beta_3 = c$ **wahr** ist, gilt in der **Grundgesamtheit** $c_1 \beta_2 + c_2 \beta_3 - c = 0$

Aufgrund von **Zufallsschwankungen** ist dieser Zusammenhang in der **Stichprobe** **nicht** exakt erfüllt: $c_1 b_2 + c_2 b_3 - c = v$

wobei **v** relativ nahe bei **null** liegen sollte, wenn H_0 wahr ist.

Wenn b_2 und b_3 normalverteilt sind, ist auch **v** **normalverteilt**.

Beispiele

t-Test für eine Linearkombination von Parametern

Wenn H_0 wahr gilt $E(v) = 0$.

Standardfehler, um eine Teststatistik zu bestimmen

$$\text{var}(v) = \text{var}(c_1 b_2 \pm c_2 b_3 - c) = c_1^2 \text{var}(b_2) + c_2^2 \text{var}(b_3) \pm 2c_1 c_2 \text{cov}(b_2, b_3)$$

Unter H_0 gilt $\frac{v}{\text{se}(v)} = \frac{c_1 b_2 \pm c_2 b_3 - c}{\sqrt{c_1^2 \text{var}(b_2) + c_2^2 \text{var}(b_3) \pm 2c_1 c_2 \text{cov}(b_2, b_3)}} \sim t_{N-k}$

$H_0: c_1 b_2 \pm c_2 b_3 = c$

Einschränkung des t-Tests: Kann **nicht** für den Test **mehrerer** Hypothesen verwendet werden!

Nicht möglich für die **simultane** Hypothese $H_0: \beta_2 = \beta_3 = 0$

t-Test für Linearkombinationen

Kann H_0 als eine einzelne **Linearkombination** dargestellt werden, so wird sie normalerweise auf Basis eines **t-Tests** überprüft.

Allgemeine Form $H_0: \mathbf{r}'\boldsymbol{\beta} = c$

Zweifachregression: $y = \beta_1 + \beta_2 x_2 + \beta_3 x_3 + u$

Beispiel $H_0: \beta_2 + \beta_3 = c \Leftrightarrow H_0: \mathbf{r}'\boldsymbol{\beta} = c \Leftrightarrow \underbrace{(0 \ 1 \ 1)}_{\mathbf{r}'} \underbrace{\begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}}_{\boldsymbol{\beta}} = c$

$$t = \frac{\mathbf{r}'\mathbf{b} - c}{\sqrt{\mathbf{r}'\text{var}(\mathbf{b})\mathbf{r}}}$$

$$t = \frac{\mathbf{r}'\mathbf{b} - c}{s_e \sqrt{\mathbf{r}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{r}}}$$

$$\underbrace{(0 \ 1 \ 1)}_{\mathbf{r}'} \underbrace{\begin{pmatrix} \text{var}(b_1) & s_{12} & s_{13} \\ s_{21} & \text{var}(b_2) & s_{23} \\ s_{31} & s_{32} & \text{var}(b_3) \end{pmatrix}}_{\text{var}(\mathbf{b})} \underbrace{\begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}}_{\mathbf{r}} = \underbrace{(0 \ 1 \ 1)}_{\mathbf{r}'} \underbrace{\begin{pmatrix} s_{12} + s_{13} \\ \text{var}(b_2) + s_{23} \\ \text{var}(b_3) + s_{23} \end{pmatrix}}_{\mathbf{r}} = \underline{\text{var}(b_2) + \text{var}(b_3) + 2s_{23}}$$

$H_0: \mathbf{r}'\mathbf{b} = c$

$$t = \frac{b_2 + b_3 - c}{\sqrt{\text{var}(b_2) + \text{var}(b_3) + 2\text{cov}(b_2, b_3)}} \sim t_{N-k}$$


F- Verteilung

Verhältnis zweier **unabhängig** χ^2 verteilter Zufallsvariablen, die beide durch die entsprechenden **Freiheitsgrade** dividiert werden.

Es seien $X_1 \sim \chi_{n_1}^2$ und $X_2 \sim \chi_{n_2}^2$ Chi-Quadrat-verteilt und unabhängig.

Zufallsvariable $F = \frac{X_1/n_1}{X_2/n_2} \sim F(n_1, n_2)$ ist **F-verteilt** mit n_1 und n_2 **Freiheitsgraden (df)**.

Die genaue Form der F-Verteilung hängt von **beiden Freiheitsgraden** ab.



F-Test: Interpretation

t-Test überprüft den Einfluss jeder **einzelnen** erklärenden Variable

F-Test testet den **gemeinsamen Einfluss** aller erklärender Variablen mit Ausnahme des Interzepts getestet werden.

Modell: $y_t = \beta_1 + \beta_2 x_{2t} + \beta_3 x_{3t} + \dots + \beta_k x_{kt} + u_t \Leftrightarrow \mathbf{Y} = \mathbf{Xb} + \mathbf{u}$

Frage: Tragen **alle** Regressoren gesamthaft zur Erklärung von y bei?

Nullhypothese H_0 : $\beta_2 = \dots = \beta_k = 0$ (F-Test: Überwindung der Einschränkung des t-Tests \rightarrow nur 1 Restriktion)

Interpretation:

Alle Koeffizienten mit Ausnahme des Interzepts (β_1) sind **simultan** gleich **null**
 \Leftrightarrow alle $K-1$ **Steigungskoeffizienten** sind **simultan** gleich **null**.

H_0 wahr \Rightarrow Regressoren x_i leisten gemeinsam **keinen Erklärungsbeitrag** für y

Alternativhypothese H_1 : H_0 trifft nicht zu \Leftrightarrow **mindestens** einer der Koeffizienten ist **ungleich null**!

Wenn **\mathbf{u}** **normalverteilt** ist und bei Zutreffen von H_0 gilt:

$$\sum (\hat{y}_i - \bar{y})^2 / \sigma^2 \sim \chi_{K-1}^2 \quad \text{und} \quad \sum_i e_i^2 / \sigma^2 \sim \chi_{N-K}^2$$

F-Test: Formel

F-Statistik:

$$F = \frac{ESS / (K - 1)}{RSS / (N - K)} \sim F_{(K-1, N-K)}$$

$$\frac{\sum (\hat{y}_i - \bar{y})^2 / \sigma^2}{\sum e_i^2 / \sigma^2} \sim \frac{\chi_{K-1}^2 / (K-1)}{\chi_{N-K}^2 / (N-K)} \sim F_{(K-1, N-K)}$$

F ist verteilt nach $F(k-1, N-k)$ mit $k-1$ Zähler- und $N-k$ Nenner-Freiheitsgraden.


$$F = \frac{ESS / (K - 1)}{RSS / (N - K)} = \frac{S_{\hat{y}\hat{y}}}{S_{ee}} \frac{N - K}{K - 1} \sim F_{(K-1, N-K)}$$

N : Anzahl Beobachtungen k : Anzahl Regressoren

F-Test: Verhältnis erklärter (ESS) und unerklärter Streuung (RSS).

Achtung: Es ist möglich, dass **kein** einziger Koeffizient signifikant von **null** verschieden ist, aber alle Koeffizienten **gemeinsam** trotzdem **signifikant** von **null** verschieden sind!

F-Test: Kritischer Wert



Für jede Verteilung $F(K-1, N-K)$ lässt sich ein kritischer Wert F_c ermitteln (Tabelle, gretl), $F_{c,0.95}$: 5% der Wahrscheinlichkeitsmasse der Verteilung liegt **rechter Hand** dieses Wertes.

F_e = empirischer Wert der F-Statistik (berechneter Wert)

F_c : kritischer Wert (aus Tabelle, gretl)

$F_e > F_c \rightarrow$ Nullhypothese auf 5%-Niveau verwerfen

F-Test: Verwerfungsregel

Wenn die durch alle erklärenden X Variablen gemeinsam **erklärte Streuung ESS** sehr klein ist im Verhältnis zur **unerklärten Streuung RSS**, würde man einen sehr kleinen Wert der empirischen Statistik F_e erwarten.


Nullhypothese $H_0: \beta_2 = \dots = \beta_k = 0$ wird verworfen, wenn der empirische Wert (F_e) > **kritischer Wert F_c** .

Der zur F-Statistik gehörende **p-Wert** ist wieder die Fläche unter der Verteilung **rechts** vom berechneten F_e -Wert.

Verwerfungsregel für H_0

- ✓ $F_e > F_c$
- ✓ $p\text{-Wert} \leq \text{Signifikanzniveau}$


$$F = \frac{ESS / (K - 1)}{RSS / (N - K)} \approx F_{(K-1, N-K)}$$




Konfidenzellipse

Bivariate Normalverteilungen ohne und mit Korrelation zwischen den Zufallsvariablen:


(A) $\rho = 0$:



(B) $\rho = -0.7$:



(C)



Wenn die Variablen **unkorreliert** sind (A) wird die gemeinsame Signifikanz durch einen **Signifikanzkreis** dargestellt, bei Korrelation zwischen den Variablen (B) durch eine **Konfidenzellipse**, die desto **schmäler** wird, je **höher** die Korrelation ist.

Die Form der **Konfidenzellipse** (C) wird vom **Korrelationskoeffizienten r** bestimmt. Eine starke Korrelation bedeutet ein langes **a** (grosse Halbachse) und ein kurzes **b** (kleine Halbachse). Die Ausrichtung der Ellipse hängt ebenfalls von **r** ab.

F-Test: Konfidenzellipse

Regressionsfunktion: $y_t = \beta_1 + \beta_2 x_{2t} + \beta_3 x_{3t} + u_t$

Variable		Coefficient	Std. Error	t-Stat.	Prob.	N = 50
const.	$\hat{\beta}_1$	7.8878	5.0277	1.5689	0.1234	
x_2	$\hat{\beta}_2$	0.1996	0.2799	0.7131	0.4793	
x_3	$\hat{\beta}_3$	0.6339	0.3442	1.8417	0.0718	
R-squared		0.5979	Log likelihood	-210.2721		
Adjusted R-squared		0.5808	S.E. of regression	16.7340		
Sum squared resid	13161.2380	F-statistic	34.9485			
Durbin-Watson Stat.	2.1632	Prob(F-statistic)	0.0000			

Einzelne t-Tests

t-Statistik $< 2 \rightarrow H_0: \beta_2 = 0$ und $H_0: \beta_3 = 0$ werden für $\alpha = 5\%$ nicht abgelehnt! Die Koeffizienten sind **individuell statistisch nicht** signifikant.

F-Test

Nullhypothese $H_0: \beta_2 = \beta_3 = 0$

$F = 34.94$ und p-Wert $= 0 \rightarrow H_0$ verwerfen

Die Koeffizienten β_2, β_3 sind **gemeinsam hochsignifikant!**

F-Test

Regressionsfunktion: $Y_t = \beta_1 + \beta_2 x_{2t} + \beta_3 x_{3t} + u_t$

Nullhypothesen


Individuelle $H_{01}: \beta_2 = 0$ und $H_{02}: \beta_3 = 0$

Gemeinsame $H_{03}: \beta_2 = \beta_3 = 0$

$\Rightarrow \beta_2, \beta_3$ gemeinsam **hochsignifikant**

Die Punkte $(0,0)$ und (β'_2, β'_3) liegen innerhalb der individuellen **Konfidenzintervalle** (H_{01} und H_{02} nicht ablehnen) aber ausserhalb der **Konfidenzellipse** (H_{03} ablehnen)

Punkt (β''_2, β''_3) liegt ausserhalb der individuellen **Konfidenzintervalle** (H_{01} und H_{02} ablehnen) aber innerhalb der **Konfidenzellipse** (H_{03} nicht ablehnen)



Gretl Output: F-Test

Modell: Pro-Kopf-Konsum = $b_1 + b_2 \text{Einkommen} + b_3 T$
 = 300.28 + 0.741 Einkommen + 8.04T

N = 15 und K = 3 und **Freiheitsgrade** = N-K = 12

Nullhypothese $H_0: \beta_2 = \beta_3 = 0 \rightarrow$ Einkommen und Zeit liefern gemeinsam keinen Erklärungsbeitrag für Konsum (y)
 $F(K-1, N-k) = F(2, 12) = 2'513.521$

Kritischer Wert: $F_c = 3.88$ p-Wert = $P[F > F_e = 2'513] = 0 < \alpha$

Empirischer Wert: $F_e = 2'513.521 > F_c \rightarrow H_0$ verwerfen

Abhängige Variable: Konsum

	Koeffizient	Std.-fehler	t-Quotient	p-Wert	
const	300,286	78,3176	3,834	0,0024	***
Einkommen	0,741981	0,0475337	15,61	2,46e-09	***
T	8,04356	2,98355	2,696	0,0195	**
Mittel d. abh. Var.	1942,333	Stdabw. d. abh. Var.	243,5044		
Summe d. quad. Res.	1976,855	Stdfehler d. Regress.	12,83503		
R-Quadrat	0,997619	Korrigiertes R-Quadrat	0,997222		
F(2, 12)	2513,521	P-Wert (F)	1,82e-16		
Log-Likelihood	-57,89317	Akaike-Kriterium	121,7863		
Schwarz-Kriterium	123,9105	Hannan-Quinn-Kriterium	121,7637		
rho	-0,496597	Durbin-Watson-Stat	2,488178		

Gretl-Output: F-Test

	Koeffizient	Std.-fehler	t-Quotient	p-Wert	
const	1000,45	225,727	4,432	0,0004	***
Ausbildung	62,4284	21,8345	2,859	0,0114	**
Alter	12,3539	10,6575	1,159	0,2634	
Dauer	-2,62034	14,2970	-0,1833	0,8569	
Mittel d. abh. Var.	1685,000	Stdabw. d. abh. Var.	375,6048		
Summe d. quad. Res.	955691,7	Stdfehler d. Regress.	244,3987		
R-Quadrat	0,643465	Korrigiertes R-Quadrat	0,576615		
F(3, 16)	9,625466	P-Wert (F)	0,000720		

Modell 3: Lohn = $b_1 + b_2 \text{Ausb.} + b_3 \text{Alter} + b_4 \text{Dauer}$

N = 20 und K = 4 und **Freiheitsgrade** (df) = N-K = 16

Nullhypothese $H_0: \beta_2 = \beta_3 = \beta_4 = 0$

$F(K-1, N-K) = F(3, 16) = 9.625$

Kritischer Wert: $F_c = 3.238$ p-Wert = $P[F > F_e = 9.625] \cong 0 < \alpha = 0.05$

Regel: $F_e = 9.625 > F_c \rightarrow H_0$ verwerfen

Konklusion: Mindestens eine erklärende Variable ist

Normal	t	chi-Quadrat	F	binomial
			Zähler-FG	3
			Nenner-FG	16
			rechtsseitige Wahrscheinlichkeit	0.05

F-Test und t-Test

- **Achtung:** Es reicht nicht zu überprüfen, ob alle Koeffizienten individuell signifikant von Null verschieden sind!
- **Multikollinearität:** Die erklärenden Variablen sind untereinander **hoch korreliert**
- **Folge:** Kein **einzig**er Koeffizient ist signifikant von **null** verschieden, aber alle Koeffizienten sind **gemeinsam** signifikant von **null** verschieden!
- **Konklusion:** Die mit der F-Statistik getestete **gemeinsame Nullhypothese** $H_0 : \beta_2 = \beta_3 = \dots = \beta_k = 0$ darf nicht durch eine Reihe **individueller t-Tests** ersetzt werden!
- **Grund:** Die F-Statistik berücksichtigt die mögliche Korrelation zwischen den OLS-Schätzern $\beta_2, \beta_3, \dots, \beta_k$, während diese bei individuellen t-Tests in dieser Form unberücksichtigt bleibt.

F-Test und R^2

Die Teststatistik des F-Tests als Funktion des **Bestimmtheitsmasses**:

$$F = \frac{ESS/(K-1)}{RSS/(N-K)} = \frac{R^2}{1-R^2} \cdot \frac{N-K}{K-1}$$

Grosser Wert von $R^2 \rightarrow$ grosser Wert von F

ANOVA Analyse = **Varianzanalyse** \rightarrow schematische Schreibweise zur Berechnung des F-Tests.

N = 20 und K = 4			
	Quadratsumme	FG	quad. Mittel
Regression	1,72481e+006	3	574936
Residuum	955692	16	59730,7
Total	2,6805e+006	19	141079

$R^2 = 1,72481e+006 / 2,6805e+006 = 0,643465$
 $F(3, 16) = 574936 / 59730,7 = 9,62547$ [p-Wert 0,0007]

$ESS/(K-1) = ESS/3$

$RSS/(N-K) = RSS/16$

$TSS/(N-1) = TSS/19$

$$F = \frac{R^2}{1-R^2} \cdot \frac{N-K}{K-1} = \frac{0,6434}{1-0,6434} \cdot \frac{16}{3} = 9,625$$

F-Wert entweder mittels R^2 oder mittels **Varianzanalyse**

F-Test in Matrixform

- **Regression:** $y_t = \beta_1 + \beta_2 x_{2t} + \beta_3 x_{3t} + \dots + \beta_k x_{kt} + u_t$
- **Nullhypothese H_0 :** $\beta_2 = \beta_3 = \dots = \beta_k = 0$
- **Allgemeine Form H_0 :** $\mathbf{R}\beta = \mathbf{q}$

$$\mathbf{R}\beta = \mathbf{q} \Leftrightarrow \begin{matrix} \begin{pmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \end{pmatrix} & \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix} & = & \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \\ \text{L} \times \text{k} & \text{K} \times 1 & & \end{matrix}$$

$L = K-1 = \# \text{ Linearkombinationen}$

Nullhypothese H_0 : $\beta_2 + \beta_3 + \dots + \beta_k = 1$ und $\beta_2 + 2\beta_3 = 0$

$$\mathbf{R}\beta = \mathbf{q} \Leftrightarrow \begin{matrix} \begin{pmatrix} 0 & 1 & 1 & 1 & \dots & 1 \\ 0 & 1 & 2 & 0 & \dots & 0 \end{pmatrix} & \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix} & = & \begin{pmatrix} 1 \\ 0 \end{pmatrix} \\ \text{2} \times \text{K} & \text{K} \times 1 & & \end{matrix}$$

$L = 2 \text{ Linearkombinationen}$

Vergleich t-Test und F-Test

- **Nullhypothese H_0 :** $\mathbf{R}\beta = \mathbf{q}$ ($L \times 1$ -Vektor)

$$F = \frac{(\mathbf{Rb} - \mathbf{q})' [\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}']^{-1} (\mathbf{Rb} - \mathbf{q}) / L}{\mathbf{e}'\mathbf{e} / (T - K)}$$

- **Nullhypothese H_0 :** $\mathbf{r}'\beta = c$ (Skalar)

$$t = \frac{\mathbf{r}'\mathbf{b} - c}{s_e \sqrt{\mathbf{r}'(\mathbf{X}'\mathbf{X})^{-1} \mathbf{r}}}$$

- Aus dem Zähler dieses Ausdrucks wird deutlich, dass der F-Test analog wie ein t-Test verstanden werden kann, nämlich als ein Vergleich der auf Basis der beobachteten Stichprobendaten berechneten Werte \mathbf{Rb} mit den in der **Nullhypothese** angegebenen Parameterwerten $\mathbf{R}\beta (=q)$.
- Ist die Differenz zwischen der Beobachtung \mathbf{Rb} und der **Nullhypothese** $\mathbf{R}\beta$ zu gross, dann wird die **Nullhypothese abgelehnt**.
- **Konklusion:** Mit Hilfe der Matrix-Notation kann eine Analogie zwischen F- und t-Test gezeigt werden!

Restringiertes vs. unrestringiertes Modell

Zahlreiche Tests beruhen auf einem Vergleich zweier Modelle.

Modell ohne Restriktionen = **unrestringiertes** Modell: $y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i$

Restriktion H_0 : $\beta_3 = 0$

- Modell **mit Restriktion** = **restringiertes** Modell: $y_i = \beta'_1 + \beta'_2 x_{2i} + u'_i$
- Wenn $\beta_3 = 0$ wahr $\rightarrow u_i = u'_i$

Restriktion H_0 : $\beta_3 = 1$

- Restringiertes Modell: $y_i = \beta''_1 + \beta''_2 x_{2i} + \beta''_3 x_{3i} + u''_i$
- Geschätztes Modell: $(y_i - x_{3i}) = b''_1 + b''_2 x_{2i} + e''_i$

Restriktion H_0 : $\beta_2 + \beta_3 = 1$

- **Restringiertes** Modell: $y_i = \beta^*_1 + \beta^*_2 x_{2i} + (1 - \beta^*_2) x_{3i} + u^*_i$
- Geschätztes Modell: $(y_i - x_{3i}) = b^*_1 + b^*_2 (x_{2i} - x_{3i}) + e^*_i$

F-Statistik:
$$F = \frac{(RSS_r - RSS)/L}{RSS/(N-K)} \approx F_{(K-1, N-K)}$$

Restringiertes vs. unrestringiertes Modell

Unrestringiertes Modell: $y_t = \beta_1 + \beta_2 x_{2t} + \beta_3 x_{3t} + u_t$ (1)

Wenn Nullhypothese $H_0: \beta_2 = \beta_3 = 0$ wahr ist:

Nullhypothesenmodell = **Restringiertes** Modell: $y_t = \beta_1 + u_t^0$ (2)

Schätzung: $e_t^0 = y_t - b_1$

OLS-Schätzung von (2) \Leftrightarrow Minimierung

$$S_{ee}^0 = \sum_t (y_t - b_1)^2 = \sum_t (y_t^2 + b_1^2 - 2y_t b_1) = \sum_t y_t^2 + N b_1^2 - 2b_1 \sum_t y_t$$

$$dS_{ee}^0 / db_1 = 2N b_1 - 2 \sum_t y_t = 0 \quad \Rightarrow \quad b_1 = \bar{y}$$

$$e_t^0 = y_t - \bar{y}$$

$$S_{ee}^0 = \sum e_t^{02} = \sum (y_t - \bar{y})^2 = S_{yy} = TSS$$

$$F = \frac{(S_{ee}^0 - S_{ee})/L}{S_{ee}/(N-K)} = \frac{(TSS - RSS)/(N-K)}{RSS/(N-K)} \approx F_{(L, N-K)}$$

L: Anzahl der formulierten Restriktionen

N-K: Anzahl der Freiheitsgrade

F-Test: US Pro-Kopf-Konsumausgaben

Abhängige Variable: Konsum

	Koeffizient	Std.-fehler	t-Quotient	p-Wert
const	300,286	78,3176	3,834	0,0024 ***
Einkommen	0,741981	0,0475337	15,61	2,46e-09 ***
T	8,04356	2,98355	2,696	0,0195 **
Mittel d. abh. Var.	1942,333	Stdabw. d. abh. Var.	243,5044	
Summe d. quad. Res.	1976,855	Stdfehler d. Regress.	12,83503	
R-Quadrat	0,997619	Korrigiertes R-Quadrat	0,997222	
F(2, 12)	2513,521	P-Wert (F)	1,82e-16	
Log-Likelihood	-57,89317	Akaike-Kriterium	121,7863	

N = 15

K = 3

N - K = 12 = FG (df)

RSS

ANOVA

	Quadratsumme	FG	quad. Mittel
Regression	828144	2	414072
Residuum	1976,86	12	164,738
Total	830121	14	59294,4

R² = 828144 / 830121 = 0,997619

TSS F(2, 12) = 414072 / 164,738 = 2513,52 [p-Wert 1,82e-016]

Restringiertes Modell

	Koeffizient	Std.-fehler	t-Quotient	p-Wert
const	1942,33	62,8726	30,89	2,78e-014 ***
Mittel d. abh. Var.	1942,333	Stdabw. d. abh. Var.	243,5044	
Summe d. quad. Res.	830121,3	Stdfehler d. Regress.	243,5044	
R-Quadrat	0,000000	Korrigiertes R-Quadrat	0,000000	

RSS

H₀: β₂ = β₃ = 0 → L = 2

$$F = \frac{(RSS_r - RSS)(N - K)}{RSS \cdot L} = \frac{830121,3 - 1976,86}{1976,86} \cdot \frac{12}{2} = 2513,52$$

$$F = \frac{(TSS_r - RSS)(N - K)}{RSS \cdot L}$$

$$F = \frac{830121,3 - 1976,86}{1976,86} \cdot \frac{12}{2} = 2513,52$$

F-Test für Gruppe von Parametern

- Nullhypothese H₀: β₃ = β₄ = 0
- Anzahl Restriktionen: L = 2
- Modell 3: Lohn = b₁ + b₂Ausb. + b₃Alter + b₄Dauer
- Restringiertes Modell mit β₃ = β₄ = 0:

	Koeffizient	Std.-fehler	t-Quotient	p-Wert
const	1354,66	94,2224	14,38	2,62e-011 ***
Ausbildung	89,2817	19,8198	4,505	0,0003 ***
Mittel d. abh. Var.	1685,000	Stdabw. d. abh. Var.	375,6048	
Summe d. quad. Res.	1260028	Stdfehler d. Regress.	264,5781	
R-Quadrat	0,529928	Korrigiertes R-Quadrat	0,503813	
F(1, 18)	20,29200	P-Wert (F)	0,000274	

Teststatistik: F(2, 16) = 2,54757, p-Wert 0,109522

Das Weglassen von Variablen verbesserte 1 von 3 Informationskriterien.

$$F = \frac{(RSS_r - RSS)(N - K)}{RSS \cdot L} = \frac{1'260'028 - 955'691,7}{955'691,7} \cdot \frac{16}{2} = 2,547$$

- Intuition:** Grosser Wert von F → Alter und Dauer leisten Erklärungsbeitrag
- F_e < F_c(2, 16) = 3.63 → H₀ nicht verwerfen
- p-Wert ≅ 10.9% > α = 5% → H₀ nicht verwerfen
- Beide Variablen Alter und Firmenzugehörigkeit sind gemeinsam nicht signifikant